


Научная работа



Слайды подготовлены на основе доклада Арсения Ашуха и Дмитрия Молчанова.

Из чего состоит научная работа?

- Чтение статей
- Проведение исследований
- Написание текстов
- Проведение презентаций

Сегодня, о том как нужно и как НЕ нужно:

- проводить исследование
- читать/писать научные тексты
- делать презентации, строить графики

Научный метод

- Любое научное утверждение
 - должно быть доказано
 - может быть опровергнуто
 - должно дополняться соображениями о том, каким образом выполняется утверждение
 - должно сопровождаться указаниями на его собственные «слабые места»
- Не следует увеличивать число сущностей без необходимости
- Эксперименты должны опровергать неверные гипотезы
- Эксперимент не должен быть подогнан под гипотезу

О чем не забывать в исследовании

- Изучение литературы
- Сравнение с существующими методами
- Статистическая значимость результатов
- Ablation study
- Мотивационные примеры
- Воспроизводимость результатов
- Сохранение всех результатов (моделей, метрик и тп)

Откуда брать статьи

Ведущие конференции по ML:

- ICML, NIPS, ICLR – общие
- ACL, NAACL, EMNLP – обработка естественного языка
- ICCV, CVPR – компьютерное зрение
- и т.д.

Откуда брать статьи

Google Scholar search results for "initialization of sparse networks". The search bar shows the query and a magnifying glass icon. Below the search bar, it says "Статьи" and "Результатов: примерно 141 000 (0,07 сек.)". There are links for "Мой профиль" and "Моя библиотечка".

On the left side, there are filters: "За все время" (All time), "C 2020", "C 2019", "C 2016", and "Выбрать даты". There are also checkboxes for "включая патенты" (include patents), "показывать цитаты" (show citations), and "Создать оповещение" (create alert).

The search results list several papers:

- Using genetic algorithms for **sparse** distributed memory **initialization**** [PDF] researchgate.net
A Arner, D Dasgupta, S Franklin - Proceedings of the 1999 ... 1999 - ieeexplore.ieee.org
... Abstract- In this paper, we describe the use of Genetic Algorithms to **initialize** a set of ... 1993), in which weights for the hidden layer (the hard locations) are **initialized** randomly ... GA significantly outperforms the random **initialization** of **Sparse** Distributed Memory in almost all cases ...
☆ Цитируется: 21 Похожие статьи Все версии статьи (6)
- The lottery ticket hypothesis: Finding **sparse**, trainable neural **networks**** [PDF] arxiv.org
J Frankle, M Carbin - arXiv preprint arXiv:1803.03635, 2018 - arxiv.org
... This forms our central experiment: 1. Randomly **initialize** a neural **network** (θ ; 80 ... We can study why randomly-**initialized** feed-forward **networks** seem to contain winning ... supports the lottery ticket hypothesis' emphasis on **initialization**: the original **initialization** withstands and ...
☆ Цитируется: 161 Похожие статьи Все версии статьи (5) 88
- Dsd: Dense-**sparse**-dense training for deep neural **networks**** [PDF] arxiv.org
S Han, J Pool, S Narang, H Mao, E Gong - arXiv preprint arXiv ..., 2016 - arxiv.org
... In the final dense phase, the pruned weights are **initialized** to zero and trained for another 50 epochs ... DSD gives the optimization a second (or more) chance during the training process to re-**initialize** from more robust **sparse** ... Other **initialization** methods are also worth trying ...
☆ Цитируется: 78 Похожие статьи Все версии статьи (6) 88
- Topological Insights in **Sparse** Neural **Networks**** [PDF] arxiv.org
L Liu, T Van der Lee, A Yaman, Z Atashgahi - arXiv preprint arXiv ..., 2020 - arxiv.org
... Given that the random **initialization** may not always guarantee ... For each density level, we **initialize** two **sparse network**s with two different random seeds as root **networks** ... First, we want to study that, **initialized** with very similar structures, how the topologies of these **networks** ...
☆ Цитируется: 1 Все версии статьи (7) 88
- A signal propagation perspective for pruning neural **networks** at **initialization**** [PDF] arxiv.org
N Lee, T Ajanthan, S Gould, PHS Torr - arXiv preprint arXiv:1906.06307, 2019 - arxiv.org
... when the layerwise dynamical isometry is ensured, as each layer is **initialized** identically (ie ... The overall process is summarized as follows: Step 1. **Initialize** a **network** with a variance scaling $\lambda(S)$ on layerwise dynamical isometry (LDI) condition orthogonal **initialization**.

[Google Scholar](#)

Arxiv-sanity interface showing search filters: "most recent", "top recent", "top hype", "friends", "discussions", and "recomm". There are buttons for "Last day" and "Last week".

Below the filters, it says "Top papers mentioned on Twitter over last day:".

The featured paper is "Neural Network Quine" by Oscar Chang and Hod Lipson, dated 3/17/2018 (v1: 3/15/2018), with a link to cs.AI | cs.NE.

Below the paper title, there are several thumbnail images of the paper's content.

Below the thumbnails, there is a text block: "Self-replication is a key aspect of biological life that has been largely overlooked self-replicating neural networks. The network replicates itself by learning to output be optimized with either gradient-based or non-gradient-based methods. We also explicit optimization, by injecting the network with predictions of its own parameters alternating between regeneration and optimization steps. Finally, we describe a task such as MNIST image classification. We observe that there is a trade-off between but training is biased towards increasing its specialization at image classification reproduction and other tasks observed in nature. We suggest that a self-replication possibility of continual improvement through natural selection."

At the bottom, it says "61 tweets:" followed by a row of tweet thumbnails.

[Arxiv-sanity](#)

Откуда брать статьи



[/r/machinelearning](https://www.reddit.com/r/MachineLearning/)



https://www.reddit.com/r/MachineLearning/comments/5jjzny/d_deep_learning_twitter_loop/

Как читать статьи

Очень популярный обзор: <http://ccr.sigcomm.org/online/files/p83-keshavA.pdf>

Основная идея – есть несколько этапов, сколько из них проходить зависит от целей:

1. Заголовок + абстракт
2. Введение, заключение, названия секций + возможно схемы
3. Беглое прочтение всей статьи
4. Доскональное прочтение всей статьи и аппендикса

Как читать статьи

arXiv:1611.03530v2 [cs.LG] 26 Feb 2017

UNDERSTANDING DEEP LEARNING REQUIRES RE-THINKING GENERALIZATION

Chiyuan Zhang^{*}
Massachusetts Institute of Technology
chiyuan@mit.edu

Samy Bengio
Google Brain
bengio@google.com

Moritz Hardt
Google Brain
mrtz@google.com

Benjamin Recht[†]
University of California, Berkeley
brecht@berkeley.edu

Oriol Vinyals
Google DeepMind
vinyals@google.com

ABSTRACT

Despite their massive size, successful deep artificial neural networks can exhibit a remarkably small difference between training and test performance. Conventional wisdom attributes small generalization error either to properties of the model family, or to the regularization techniques used during training. Through extensive systematic experiments, we show how these traditional approaches fail to explain why large neural networks generalize well in practice. Specifically, our experiments establish that state-of-the-art convolutional networks for image classification trained with stochastic gradient methods easily fit a random labeling of the training data. This phenomenon is qualitatively unaffected by explicit regularization, and occurs even if we replace the true images by completely unstructured random noise. We corroborate these experimental findings with a theoretical construction showing that simple depth two neural networks already have perfect finite sample expressivity as soon as the number of parameters exceeds the number of data points as it usually does in practice. We interpret our experimental findings by comparison with traditional models.

1 INTRODUCTION

Deep artificial neural networks often have far more trainable model parameters than the number of samples they are trained on. Nonetheless, some of these models exhibit remarkably small *generalization error*, i.e., difference between “training error” and “test error”. At the same time, it is certainly easy to come up with natural model architectures that generalize poorly. What is it then that distinguishes neural networks that generalize well from those that don’t? A satisfying answer to this question would not only help to make neural networks more interpretable, but it might also lead to more principled and reliable model architecture design.

To answer such a question, statistical learning theory has proposed a number of different complexity measures that are generalization error. These include VC dimension (Vapnik, 1998), Rademacher complexity (Bartlett & Mendelson, 2003), and uniform stability (Mukherjee et al., 2002; Bousquet & Elisseeff, 2002; Poggio et al., 2004). Moreover, when the number of parameters is large, theory suggests that some form of regularization is needed to ensure small generalization error. Regularization may also be implicit as is the case with early stopping.

1.1 OUR CONTRIBUTIONS

In this work, we problematize the traditional view of generalization by showing that it is incapable of distinguishing between different neural networks that have radically different generalization performance.

^{*}Work performed while interning at Google Brain.

[†]Work performed at Google Brain.

Variational Dropout Sparsifies Deep Neural Networks

Dmitry Molchanov^{1,2*} Arsenii Ashukha^{3,4*} Dmitry Vetrov^{3,1}

Abstract

We explore a recently proposed Variational Dropout technique that provided an elegant Bayesian interpretation to Gaussian Dropout. We extend Variational Dropout to the case when dropout rates are unbounded, propose a way to reduce the variance of the gradient estimator and report first experimental results with individual dropout rates per weight. Interestingly, it leads to extremely sparse solutions both in fully-connected and convolutional layers. This effect is similar to automatic relevance determination effect in empirical Bayes but has a number of advantages. We reduce the number of parameters up to 280 times on LeNet architectures and up to 68 times on VGG-like networks with a negligible decrease of accuracy.

1. Introduction

Deep neural networks (DNNs) are a widely popular family of models which is currently state-of-the-art in many important problems (Szegedy et al., 2016; Silver et al., 2016). However, DNNs often have many more parameters than the number of the training instances. This makes them prone to overfitting (Hinton et al., 2012; Zhang et al., 2016) and necessitates using regularization. A commonly used regularizer is Binary Dropout (Hinton et al., 2012) that prevents co-adaptation of neurons by randomly dropping them during training. An equally effective alternative is Gaussian Dropout (Srivastava et al., 2014) that multiplies the outputs of the neurons by Gaussian random noise.

Dropout requires specifying the dropout rates which are the

^{*}Equal contribution ¹Yandex, Russia ²Skolkovo Institute of Science and Technology, Skolkovo Innovation Center, Moscow, Russia ³National Research University Higher School of Economics, Moscow, Russia ⁴Moscow Institute of Physics and Technology, Moscow, Russia. Correspondence to: Dmitry Molchanov <dmitry.molchanov@skolovotech.ru>, Arsenii Ashukha <ars.ashukha@gmail.com>, Dmitry Vetrov <vetrov@yandex.ru>.

Proceedings of the 34th International Conference on Machine Learning, Sydney, Australia, PMLR 70, 2017. Copyright 2017 by the author(s).

probabilities of dropping a neuron. The dropout rates are typically optimized using grid search. To avoid the exponential complexity of optimizing multiple hyperparameters, the dropout rates are usually shared for all layers. Recently it was shown that dropout can be seen as a special case of Bayesian regularization (Gul & Ghahramani, 2015; Kingma et al., 2015). It is an important theoretical result that justifies dropout and at the same time allows us to tune individual dropout rates for each weight, neuron or layer in a Bayesian way.

Instead of injecting noise we can regularize a model by reducing the number of its parameters. This technique is especially attractive in the case of deep neural networks. Modern neural networks contain hundreds of millions of parameters (Szegedy et al., 2015; He et al., 2015) and require a lot of computational and memory resources. It restricts us from using deep neural networks when those resources are limited. Inducing sparsity during training of DNNs leads to regularization, compression, and acceleration of the resulting model (Han et al., 2015a; Scardapane et al., 2016).

Sparse Bayesian Learning (Tipping, 2001) provides a principled framework for training of sparse models without the manual tuning of hyperparameters. Unfortunately, this approach does not extend straightforwardly to DNNs. During past several years, a number of papers (Hoffman et al., 2013; Kingma & Welling, 2013; Rezzende et al., 2014) on scalable variational inference have appeared. These techniques make it possible to train Bayesian Deep Neural Networks using stochastic optimization and provide us an opportunity to transfer Bayesian regularization techniques from simple models to DNNs.

In this paper, we study Variational Dropout (Kingma et al., 2015) in the case when each weight of a model has its individual dropout rate. We propose Sparse Variational Dropout that extends Variational Dropout to all possible values of dropout rates and leads to a sparse solution. To achieve this goal, we provide a new approximation of the KL-divergence term in Variational Dropout objective that is tight on the full domain. We also propose a way to greatly reduce the variance of the stochastic gradient estimator and show that it leads to a much faster convergence and a better value of the objective function. We show theoretically that

Какие тексты приходится писать?

- Курсовые работы / дипломные работы / диссертации / ...
- Рецензии на КР / ВКР и доклады

В научном мире:

- Статьи
- Рецензии на статьи / Ответы на рецензии (ребатл)
- Заявки на гранты

В индустрии тоже нужно уметь писать тексты про результаты своей работы!

Какие приходится делать доклады?

- Презентация статьи на семинаре
- Защита курсовой / диплома / диссертации
- Презентация статьи на конференции

Основные различия – ограничение по времени и подробность изложения

С чего начать подготовку?

- Изучить материал, чтобы понять примерный план доклада
- Понять стартовые и конечные точки (принять во внимание уровень подготовки аудитории и временные рамки доклада) и составить список основных пунктов, которые слушатели должны вынести из вашего доклада – учитывайте время доклада!
- Составить план доклада – основные пункты и логические переходы между ними
- Сделать презентацию (по ходу будут вноситься правки в план)

Структура доклада

- Титульный слайд
- (Optional) План доклада
- Постановка проблемы и мотивация
- Постепенный ввод необходимых обозначений и понятий
- Описание основной идеи работы, желательно на примерах
- (Optional) Более подробное описание, технические детали
- Эксперименты
- Заключение

Как делать презентации

- Презентация помогает рассказчику, дополняет рассказ
- Что говорить с этим слайдом → что писать на слайде
- Один слайд на 1-2 минуты
 - Не стоит делать больше 20 слайдов в презентации на полчаса
- Читаемый шрифт (здесь 18pt) (мельче (14) делать (12) не стоит (10))
- Несколько простых слайдов лучше одного сложного
- Цвета – рамки – стрелки

Хорошо в меру

Как делать презентации

Оглавление

1. Часть 1
2. Часть 2
3. Часть 3

- Простой белый фон лучше картинки
- Простой шаблон лучше перегруженного
- Анимированные переходы – зло
- Не забудьте выйти из мессенджеров и закрыть вкладки
 - Можно зайти с чистого пользователя
- И НЕ НАДО ПИСАТЬ КАПСОМ
 - Да, даже заголовки



BL | LilRobot
is now playing
WHO DRIVES A FORD?



Leverette
is now playing
You're all haterz



Crest
is now playing
u mad Forderette?

Как делать презентации

Длинные абзацы текста в презентации на устном докладе считаются дурным тоном. Они гораздо тяжелее читаются, и слушателю приходится отвлекаться от, собственно, рассказа докладчика, чтобы все-таки прочитать эту стену текста. Обычно информацию можно донести более эффективно.

- Списки читаются гораздо проще
- На слайды нужно выносить ключевые идеи
- Не обязательно писать полные предложения

How to make a presentation

- Slides in English on a Russian talk are still OK
- Easy to reuse slides
- You can put the presentation on your homepage
- Не мешайте языки вместе

Формулы в презентации

- Идеи первичны
- Формулы должны иллюстрировать доклад, а не быть самоцелью
- Стараться опускать тяжелые выкладки

$$\text{LogN}_{[a,b]}(x \mid \mu, \sigma^2) = \frac{1}{Zx\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(\log x - \mu)^2\right), \log x \in [a, b], x > 0$$

$$\begin{aligned} \text{Var}\left[x \sim \text{LogN}_{[a,b]}(x \mid \mu, \sigma^2)\right] &= \frac{1}{Z} \int_{e^a}^{e^b} \frac{(x - \mathbb{E}x)^2}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(\log x - \mu)^2\right) dx = \\ &= \frac{1}{Z} \left[\int_{e^a}^{\infty} \frac{(x - \mathbb{E}x)^2}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(\log x - \mu)^2\right) dx - \int_{e^b}^{\infty} \frac{(x - \mathbb{E}x)^2}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(\log x - \mu)^2\right) dx \right] \end{aligned}$$

Формулы в презентации

- Идеи первичны
- Формулы должны иллюстрировать доклад, а не быть самоцелью
- Стараться опускать тяжелые выкладки
- Все формулы надо проговаривать
- Большие формулы \Rightarrow используем выделение

$$\mathbb{E}_{q(\tilde{W} | \phi)} \log p(y | x, \tilde{W}) - D_{KL}(q(\tilde{W} | \phi) || p(\tilde{W})) \rightarrow \max_{\phi}$$

Data-term e.g. cross-entropy loss	Regularizer i.e. KL-distance
---	--

Как готовиться к выступлению

- Продумать, о чем говорить на каждом слайде
 - Можно писать план в speaker notes
- Доклад до 15 минут можно выучить наизусть
- Продумать интонации – нужно рассказывать, а не монотонно зачитывать
- Особенно поначалу очень важно репетировать
 - Не смотря в написанный текст
 - Стоя и говоря вслух
 - С диктофоном / камерой / другом / ...
 - С часами (!)

Как не волноваться на выступлении

- Никак :)
- Со стороны сложно заметить волнение
- Обычно цель аудитории – понять доклад, а не ругать / высмеивать докладчика
- Можно выучить первую и последнюю минуты доклада наизусть
- Или весь доклад целиком (если он <15 минут)
- С каждым разом становится немного проще

Заключение

- Умение работать с научными статьями, выступать с докладами и писать тексты – важная часть научной (и не только) работы
- Это достаточно технические навыки, которые можно и нужно развивать
- Именно для этого мы все тут и собрались

Спасибо за внимание!

Время для вопросов!



- Так тоже не надо делать
- Лучше остановиться на слайде с заключением