
# Training a Helpful and Harmless Assistant with Reinforcement Learning from Human Feedback

Обзор-рецензия Выполнила: Аланова Ширин

# Вклад статьи







#### Опыт работы



#### Member Of Technical Staff

Anthropic · Полный рабочий день

июль 2021 г. – настоящее время · 1 г. 8 мес. San Francisco Bay Area



#### Sherman Fairchild Postdoctoral Fellow

Caltech

сент. 2018 г. - июль 2021 г. · 2 г. 11 мес.

Three-year postdoctoral fellowship in theoretical physics, supported by the Walter Burke Institute for Theoretical Physics

#### Образование



#### Princeton University

Doctor of Philosophy (PhD), Physics

2013 - 2018

Theoretical particle physics. Adviser: Nima Arkani-Hamed (Institute for Advanced Study, Princeton)



#### University of Toronto

Bachelor of Science (BSc), Honors Physics & Mathematics

2009 - 2013

Средний балл: 4.00/4.00 GPA



## Yuntao Bai

Цитирования: NLP ~ 60 статей Физмка ~ 600 статей

Предположительно начал заниматься ML с 2021 года

#### Опыт работы



Member Of Technical Staff

Anthropic

окт. 2021 г. – настоящее время · 1 г. 5 мес.

Team lead working on [redacted]. Language models, RL, scaling laws, and safety.

## Образование



The University of Edinburgh

Master of Arts (M.A.), Mathematics 2008 - 2012

Средний балл: First Class Honours



Abbot Beyne Comprehensive School 2001 - 2008



**Andy Jones** 

Есть собственная страничка: <a href="https://andyljones.com/">https://andyljones.com/</a>

#### Опыт работы



#### Member Of Technical Staff

Anthropic · Полный рабочий день апр. 2021 г. – настоящее время · 1 г. 11 мес. San Francisco

Working on scaling and reinforcement learning, towards reliable, interpretable, and steerable Al systems.



#### Member of Technical Staff

Stealth Co · Полный рабочий день aпр. 2021 г. · 1 мес. San Francisco, California, United States



#### OpenAI 1 г. 2 мес.

Member Of Technical Staff (Fellow)

сент. 2020 г. - март 2021 г. · 7 мес.

Scholar

февр. 2020 г. - авг. 2020 г.  $\cdot$  7 мес. San Francisco, California, United States

#### Образование





Montgomery Blair High School



# Kamal Ndousse

Специалист в области обучения с подкреплением

## Остальные

Amanda Askell, Anna Chen, Nova DasSarma, Dawn Drain, Stanislav Fort, Deep Ganguli, Tom Henighan, Nicholas Joseph, Saurav Kadavath, Jackson Kernion,

Tom Conerly, Sheer El-Showk, Nelson Elhage, Zac Hatfield-Dodds,

Danny Hernandez, Tristan Hume, Scott Johnston, Shauna Kravec, Liane Lovitt,

Neel Nanda, Catherine Olsson, Dario Amodei, Tom Brown, Jack Clark,

Sam McCandlish, Chris Olah, Ben Mann, Jared Kaplan\*

# Лаборатория

## ANTHROP\C

Building Reliable, Interpretable, and Steerable AI systems

- была основана в 2021 году бывшими старшими членами OpenAI
- С конца 2022 года Google инвестировала в компанию почти 400 миллионов долларов
- Claude собственный чат-бот с искусственным интеллектом компании Anthropic. Создатели бывшие исследователи, участвовавшие в разработке OpenAl ChatGPT

## Статьи

### Ссылаются на:

- A General Language Assistant as a Laboratory for Alignment
- Статьи в сфере e few-shot тестирования, helpful и harmless формализации

## Цитируются:

- Constitutional AI: Harmlessness from AI Feedback
- Scaling Laws for Reward Model Overoptimization
- Inclusive Artificial Intelligence

## Статьи

## Конкуренты:

- <u>Training language models to follow instructions with human feedback</u> (4 March 2022)
- Teaching language models to support answers with verified quotes (16-21 March 2022) LaMDA: Language Models for Dialog Applications (10 February 2022)
- **Open-Assistant:**

# **Open Assistant**

Разговорный ИИ для каждого.




# Сильные стороны статьи

Адаптивность и самосовершенствование

Универсальность и полезность метода

• Большое количество иллюстраций в статье





# Слабые стороны статьи

• Сложность воспроизведения результатов



• Неудобная и странная структура текста

• Размер статьи не соотносится с новизной знаний



# Спасибо за внимание)