What Can Transformers Learn In-Context? A Case Study of Simple Function Classes

Shivam Garg, Dimitris Tsipras, Percy Liang, Gregory Valiant

In-context learning

maison
$$\rightarrow$$
 house, chat \rightarrow cat, chien \rightarrow dog prompt completion

In-context learning / обучение по контексту – модель без fine-tuning способна решать новую задачу, получая на вход лишь небольшую подсказку.

Пример выше, для сложных моделей: GPT-3 по силам даже сделать перевод с французского на английский

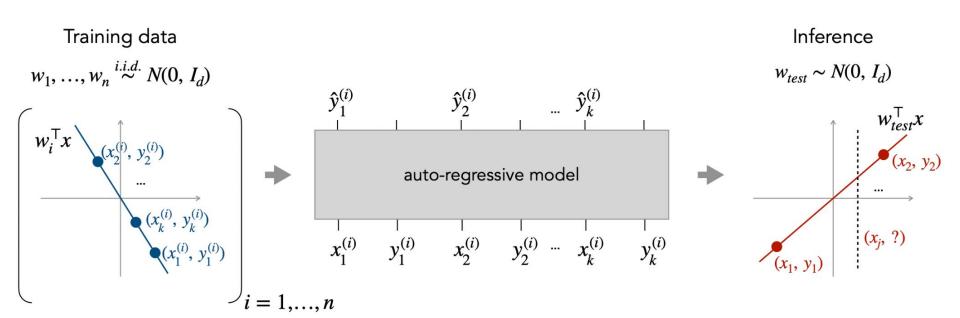
Линейные функции из распределения $\,D_{\mathcal{F}}\,$

 x_{i} $x_{
m query}$ из распределения $D_{\mathcal{X}}$

$$(x_1, f(x_1), \dots, x_k, f(x_k), x_{query})$$
 - последовательность подсказок

$$\mathbb{E}_{P}\left[\ell\left(M\left(P\right),f\left(x_{\mathrm{query}}\right)\right)\right]\leq\epsilon$$
,

Линейные функции

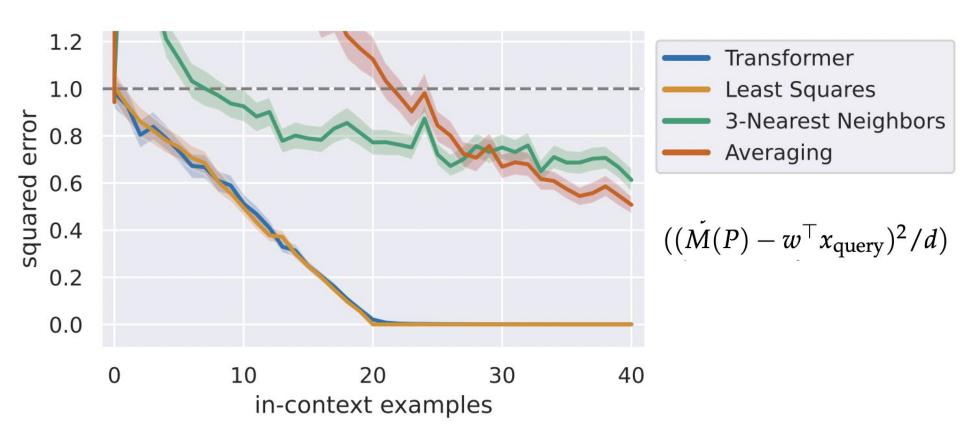


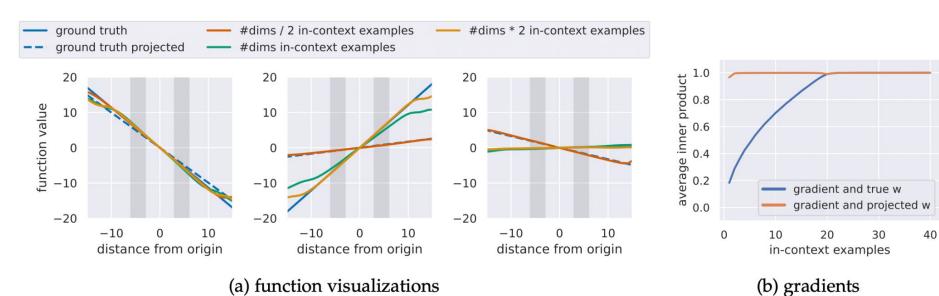
Пример того, как мы обучаем модель определять линейную зависимость

Квадратичная формула обучения

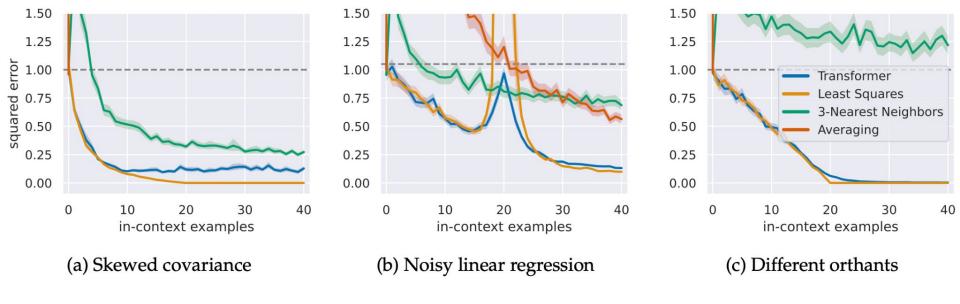
$$\min_{\theta} \mathbb{E}_{P} \left[\frac{1}{k+1} \sum_{i=0}^{k} \ell \left(M_{\theta} \left(P^{i} \right), f \left(x_{i+1} \right) \right) \right]$$

Квадратичная ошибка модели Transformer на линейных функциях

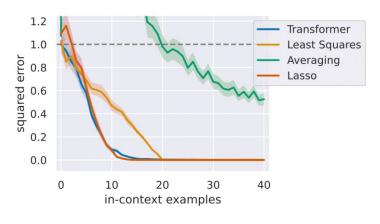


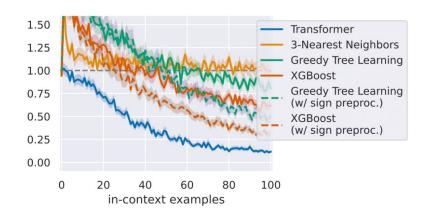


Сдвиги



Более сложные функции



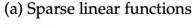


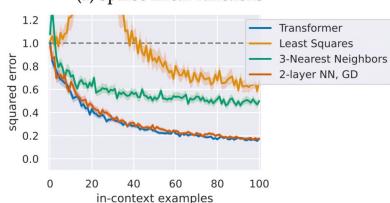
Transformer

Least Squares

2-layer NN, GD

3-Nearest Neighbors





80

100

(d) 2-layer NN, eval on linear functions

60

in-context examples

40

(b) Decision trees

1.0

0.8

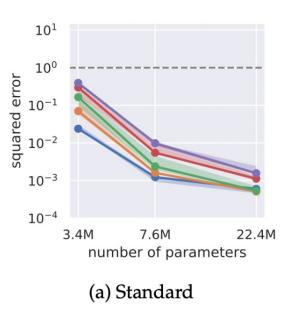
0.6 0.4

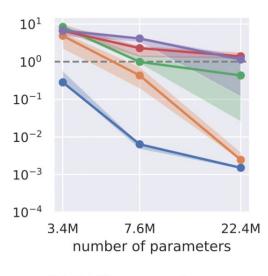
0.2

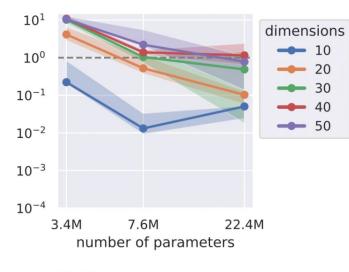
0.0

(c) 2-layer NN

In/Out distribution подсказок







(b) Different orthants

(c) Skewed covariance

Спасибо за внимание!

Обзор научного контекста

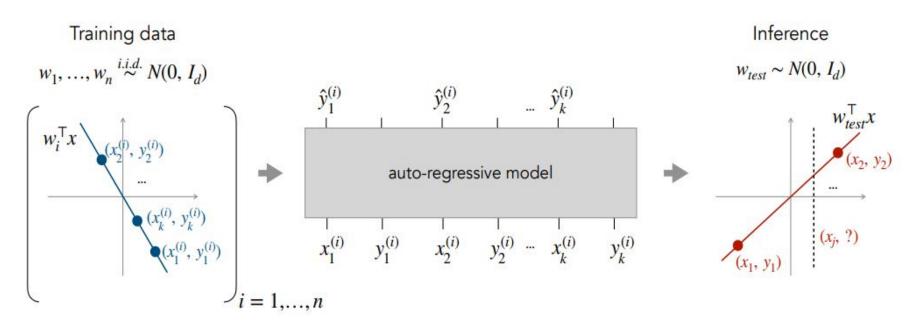
Суть работы

$$\underbrace{\mathsf{maison} \to \mathsf{house}, \, \mathsf{chat} \to \mathsf{cat}, \, \mathsf{chien} \to \underbrace{\mathsf{dog}}_{\mathsf{completion}}}_{\mathsf{prompt}}.$$

In-context learning / обучение по контексту – модель без fine-tuning'а способна решать новую задачу, получая на вход лишь небольшую подсказку.

В примере выше – перевод с французского на английский.

Суть работы



Пример того, как это выглядит для линейных функций

Про публикацию

- Опубликована 1 августа 2022 года
- Только у одного из исследователей есть другая работа, связанная с in-context learning, поэтому статья является скорее случайно находкой, нежели продолжением серии изысканий

Про публикацию

• 4 автора из Стенфорда (2 доцента и 2 аспиранта, находящихся под их руководством)



Shivam Garg 40 цитирований



Dimitris Tsipras 4950 цитирований



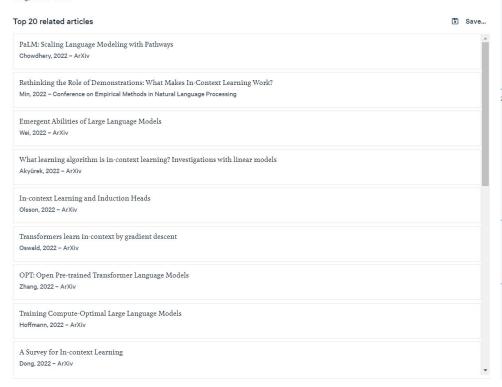
Percy Liang 9875 цитирований

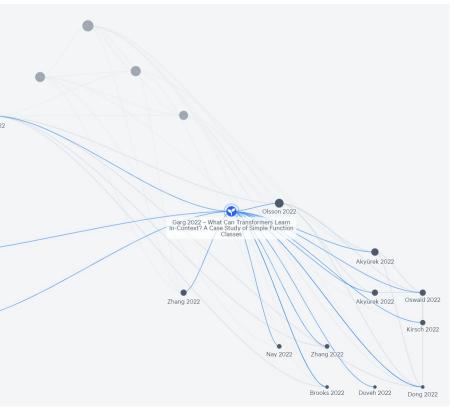


Gregory Valiant 674 цитирований

Related work – Litmap

What Can Transformers Learn In-Context? A Case Study of Simple Function Classes Garg, 2022 - ArXiv





Related work

Можно выделить 4 связанных с работой области:

- 1. In-context learning
- 2. Transformers
- 3. Meta learning (learning to learn)
 - a. учим "meta-learner" обновлять параметры при обучении на разные последующие задачи
 - учим значения параметров, из которых можно решать большое количество разных типов задач
- 4. Data-driven algorithm design

Related work / In-context Learning

- 1. "Language Models are Few-Shot Learners" Brown et al. 2020
 - а. Известная и объемная работа
 - b. Одна из ключевых для in-context
- 2. "An explanation of in-context learning as implicit bayesian inference" Xie et al. 2022
 - а. Все авторы из Стенфорда, один общий доцент
 - b. Рассматривает контекстное обучение как скрытый байесовский вывод
 - с. Предлагают фреймворк для байесовского вывода, который объясняет, как работает контекстное обучение

Related work / Transformers

- 1. "Attention is all you need" Vaswani et al. 2017 и другие
- 2. "Transformers can do bayesian inference" Müller et al. 2021
 - а. вводят "Prior-data fitted transformer"
 - b. Обучаем аппроксимировать байесовский вывод с гауссовскими процессами и байесовскими нейронными сетями в качестве априорных распределений
 - с. полученные знания используются для решения разных задач, например, классификации на табличных данных или few-shot классификации картинок
 - d. по сути очень похоже на TabPFN

Цитирования и продолжения

Цитирования:

- 7 на Google Scholar
- 17 на Semantic Scholar

Развития работы:

- "General-Purpose In-Context Learning by Meta-Learning Transformers", 8 декабря 2022 года
- "Why Can GPT Learn In-Context? Language Models Secretly Perform Gradient Descent as Meta-Optimizers",
 20 декабря 2022 года

Сильные стороны

- 1. Наличие исходного кода в открытом доступе
- 2. Основательность, с которой авторы подошли к исследованию и проведению экспериментов
 - а. зависимость от данных, на которых обучается модель
 - b. устойчивость контекстно обученных трансформеров к сдвигам распределений подсказок
 - с. факторы, влияющие на контекстное обучение (размерность задачи и размер модели)
- 3. Inductive bias трансформеров, как архитектуры (какие классы функций им сложнее / проще выучивать по контексту)
- 4. Обширная формализация, почти нет лишних обозначений

Слабые стороны

- 1. Слабо структурированный демонстрационный ірупь-ноутбук с небольшим количеством комментариев
- 2. Мало примеров про контекстное обучение, из-за чего в работу тяжело быстро вникнуть
- 3. Есть повторения в тексте